01 avril 2026

Ecosystème Big Data

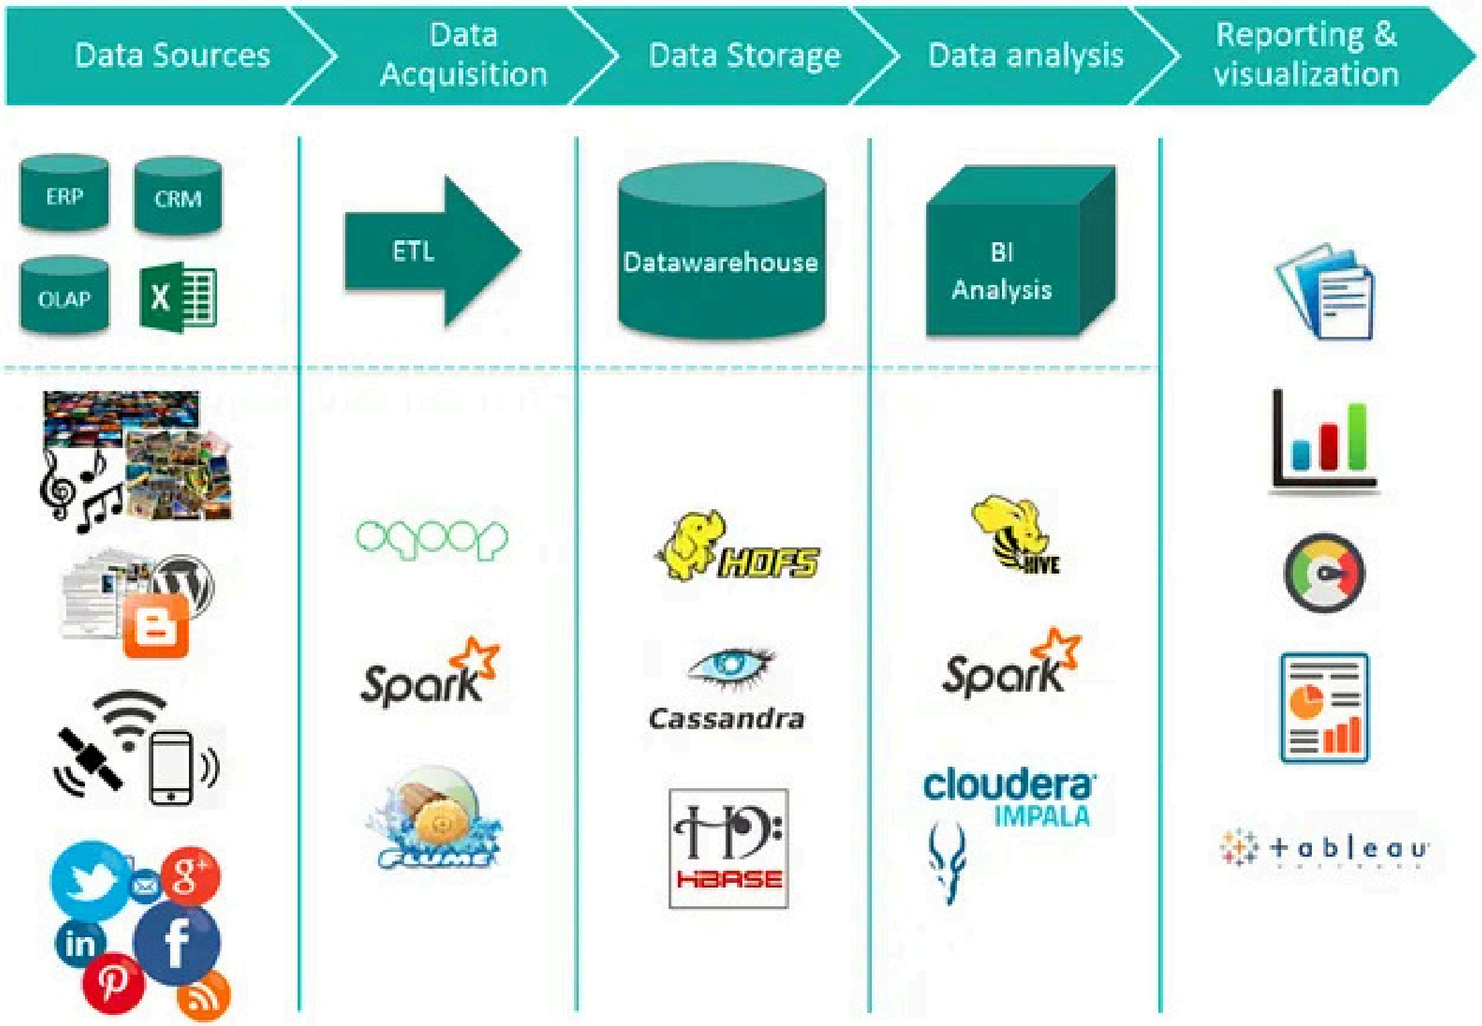

B2 BIG DATA & IA

FORMATEUR : DIALLO ALIMOU

OBJECTIFS PÉDAGOGIQUES

- Comprendre les enjeux du **Big Data** et les limites des approches traditionnelles.
- Maîtriser **l'écosystème Hadoop** : **HDFS**, **YARN**, **MapReduce** et manipulation de données.
- Utiliser Apache **Spark** : **RDD**, **DataFrames**, **Spark SQL**, transformations, streaming et optimisation.
- Manipuler **Google BigQuery** : ingestion, requêtes à grande échelle, optimisation des coûts et **BigQuery ML**.
- Comparer **Hadoop**, **Spark** et **BigQuery** pour choisir l'outil adapté et concevoir une **architecture Big Data** moderne.

INTRODUCTION BIG DATA + ÉCOSYSTÈME HADOOP

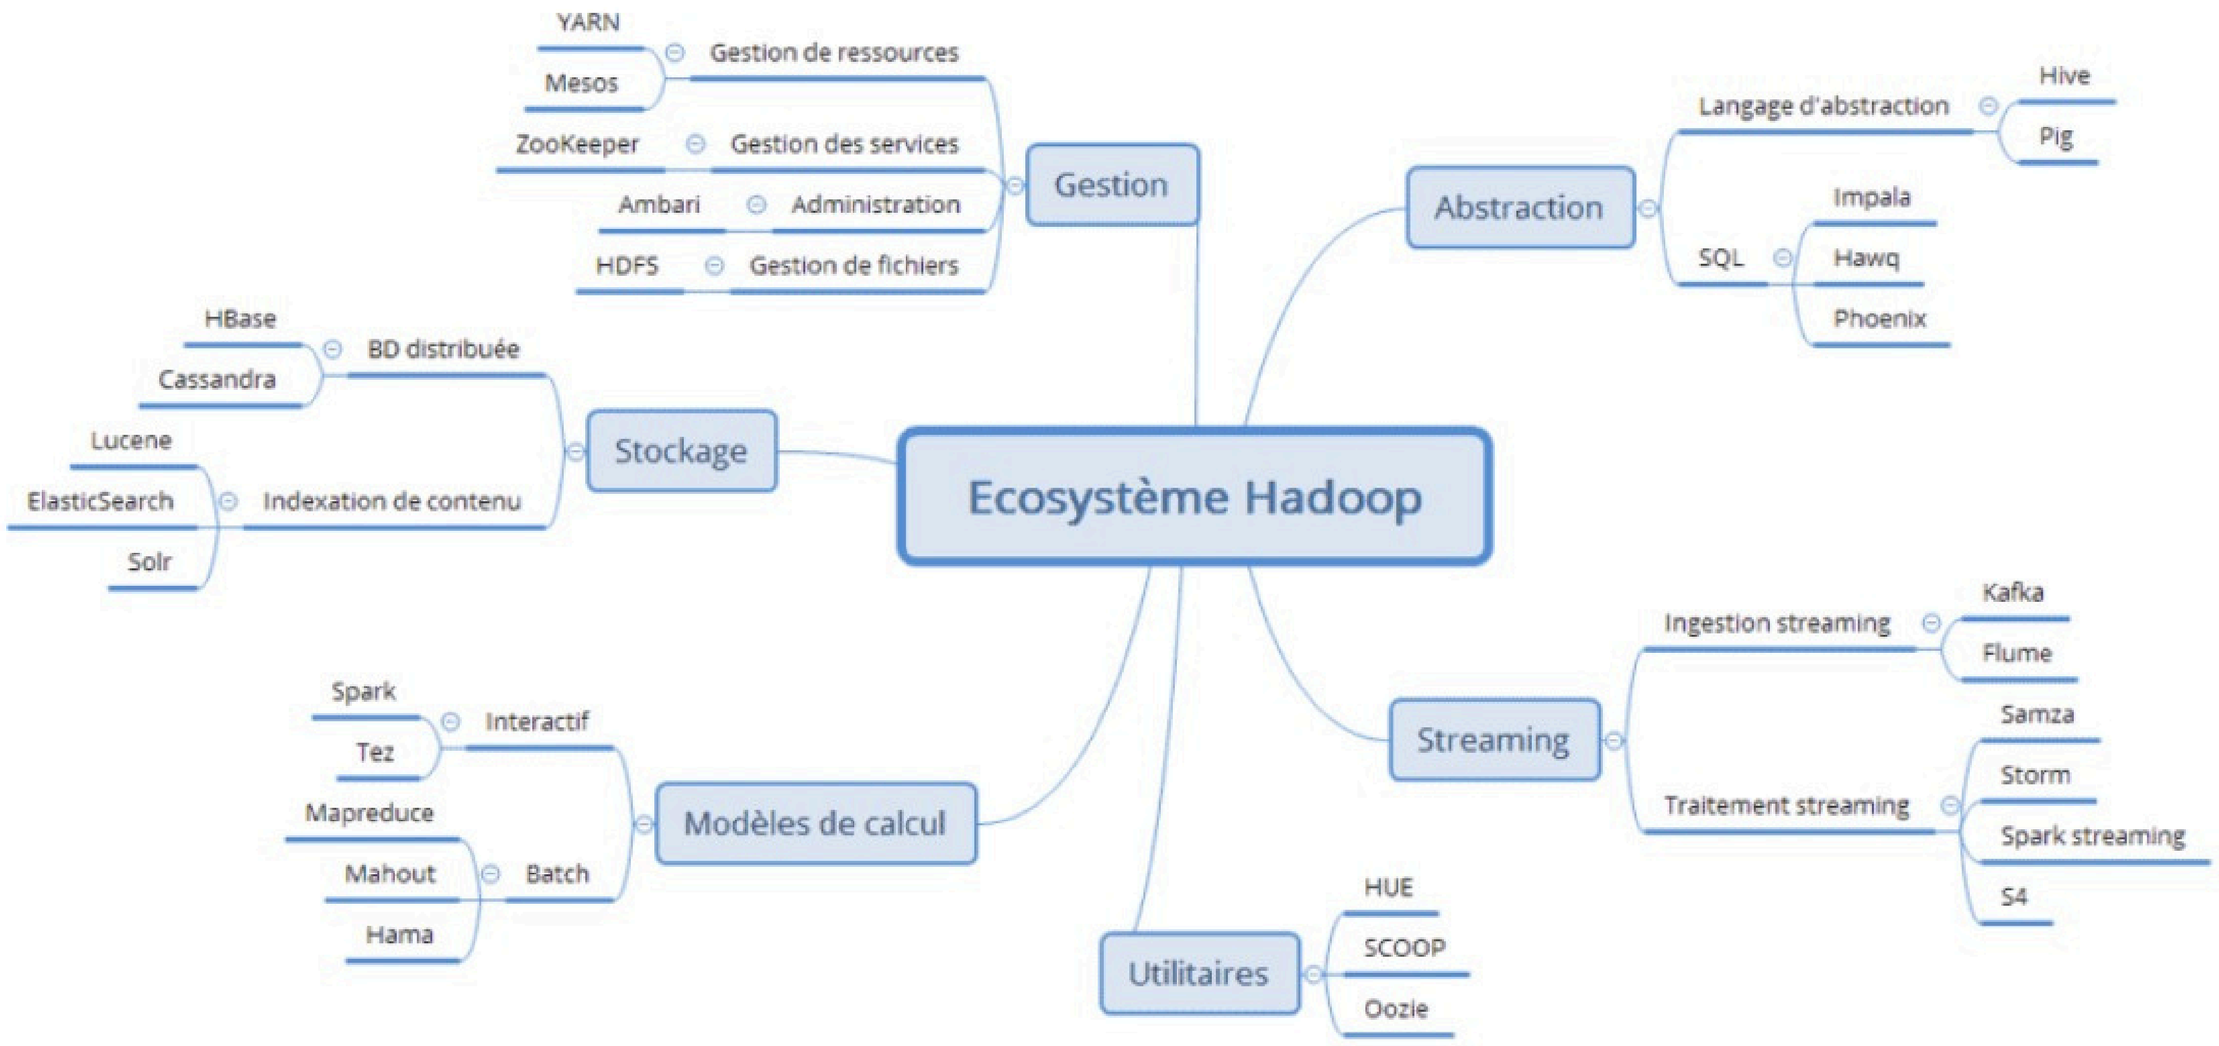

Le Big Data, également appelé « **mégas données** », « **grosses données** » ou encore « **données massives** », désigne un ensemble de données très volumineux difficile à travailler avec les outils classiques de gestion de base de données et de gestion de l'information.

Big Data : Les 3 V

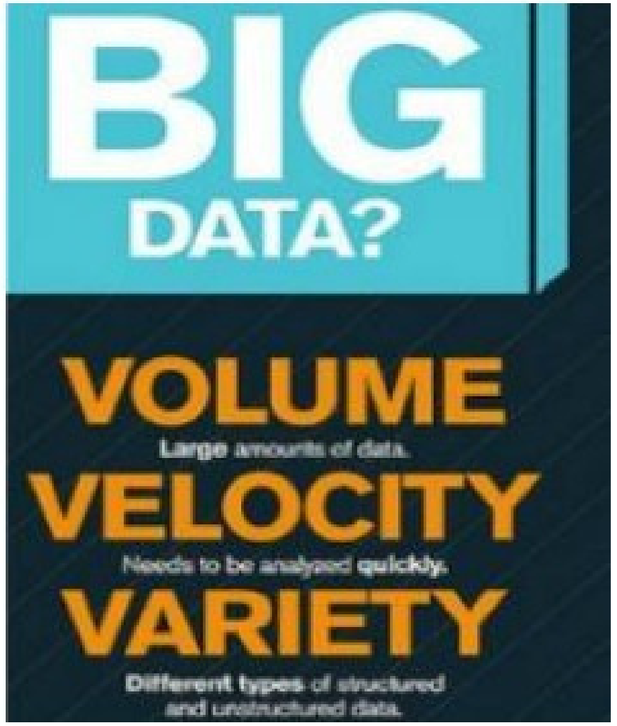

- Les données stockées augmentent 4 fois plus vite que l'économie mondiale.
- Environ 2,5 trillions d'octets de données sont produites chaque jour.

CARACTÉRISTIQUES DU BIG DATA :

Volume

- **Volume des données**
  - Augmentation de 44x entre 2009 et 2020
  - De 0.8 zettabytes à 35zb
- **Augmentation exponentielle du volume**

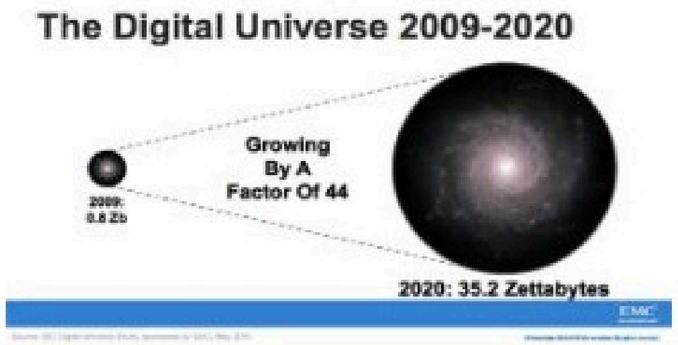

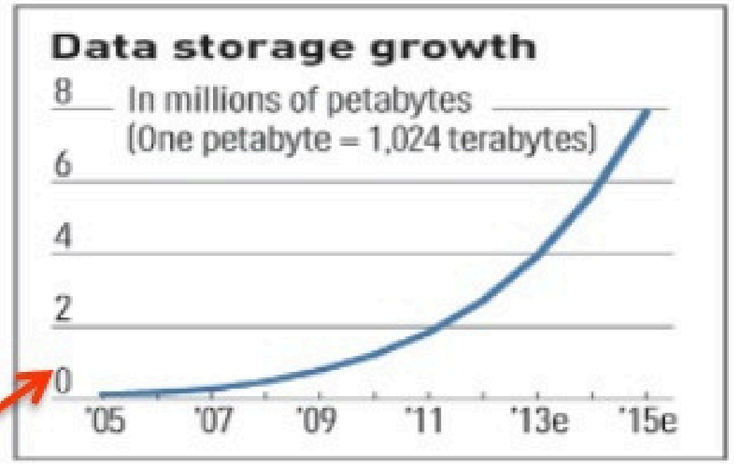

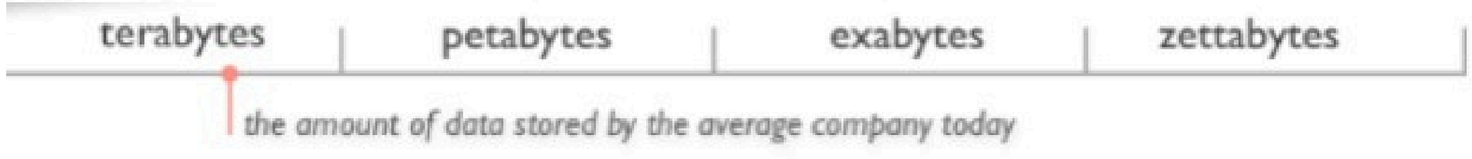

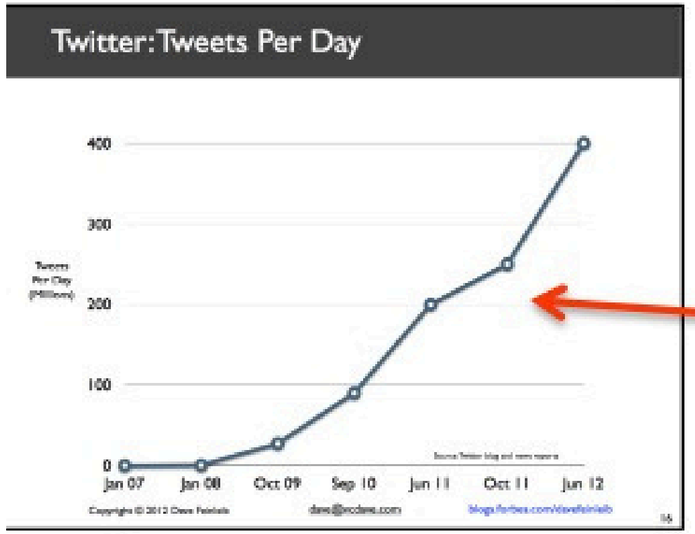

Augmentation exponentielle en données collectées/générées

Vitesse (Vélocité)

- **Les données sont générées à la volée avec une grande fréquence et doivent être traitées rapidement**
- **Analyse à la volée (online)**
- **Décisions tardives ➔ pertes d'opportunitées**

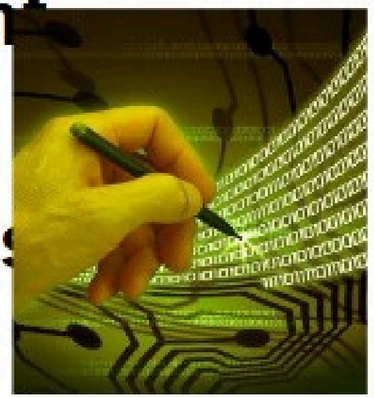

- **Exemples**
  - **E-Promotions:** Basé sur votre localisation, votre historique d'achats, ce que vous aimez ➔ envoi de promotions pour les magasins proches de vous
  - **Surveillance de la santé :** des capteurs surveillent vos activités et signaux vitaux ➔ toute mesure anormale requiert une réaction immédiate

CARACTÉRISTIQUES DU BIG DATA :

Complexité (Variété)

- Des formats, types et structures variées
- Textes, nombres, images, audio, vidéo, séquences, séries temporelles, données réseaux sociaux, données multidimensionnelles etc…
- Données statiques vs. flux de données (streaming)
- Une même application peut collecter/générer de nombreux types de données

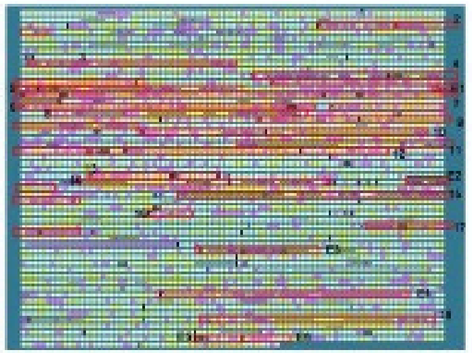

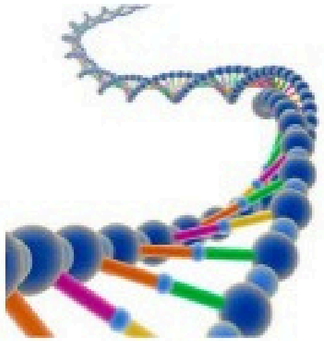

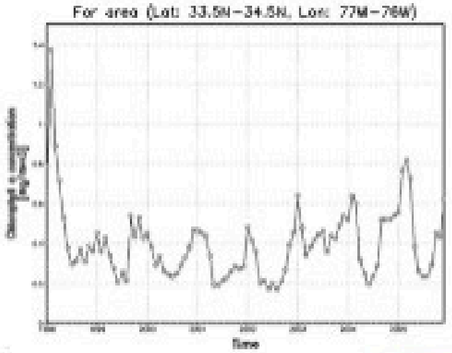

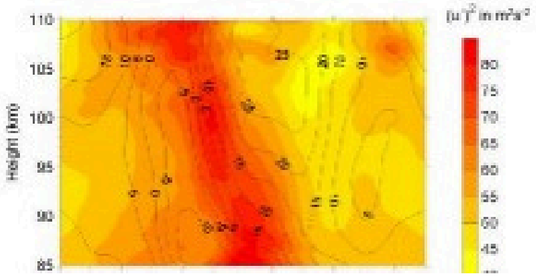

LIMITATIONS DU TRAITEMENT TRADITIONNEL

- Systèmes centrés sur une seule machine
- Problèmes de scalabilité
- Stockage coûteux ou limité
- Temps de traitement trop long pour des volumes massifs
- Incapacité à gérer le temps réel ou des flux continus
- Formats de données trop variés pour les outils classiques

D'OÙ VIENT LE "BIG DATA"?

- **Science**
  - Données d'astronomie, de génomique,environnementales, de transports,
- **Sciences Humaines et Sociales**

  Livres numérisés, documents historiques, données d'interaction sociales, traces GPS, **Business & Commerce**
-
  - Ventes, données boursières, traffic aérien, …
- **Loisirs**
  - Images, vidéo, films, MP3, …
- **Médecine**
  - Imagerie médicale, dossiers médicaux, …

Architecture Lambda

- Double pipeline : Batch + Streaming
- Combine précision (batch) et rapidité (stream)

Architecture Kappa

- Un seul pipeline : Streaming-first
- Recalcul des données via relecture du flux
- Simpler, adapté aux systèmes en temps réel

PANORAMA DE L'ÉCOSYSTÈME BIG DATA

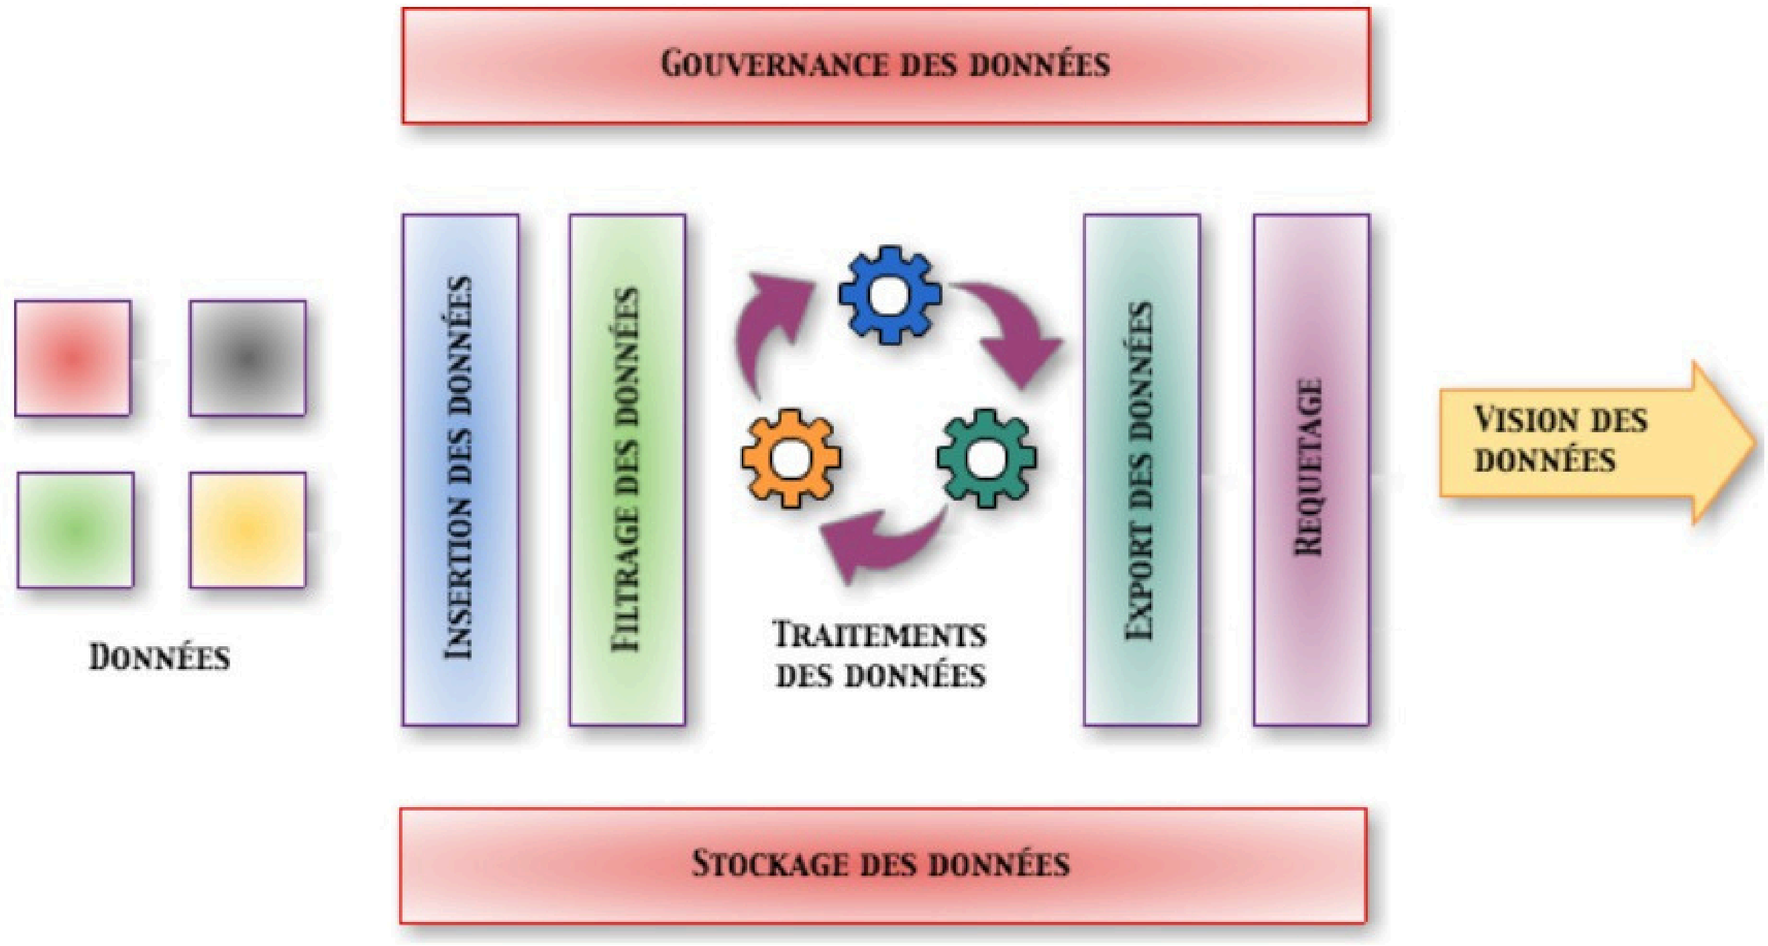

PANORAMA DE L’ÉCOSYSTÈME BIG DATA

Le Big Data repose sur un ensemble d’outils spécialisés, chacun répondant à un besoin précis :

Stockage distribué

Traitement batch et temps réel

Streaming de données

Orchestration des workflows

Analyse et entreposage de données

STOCKAGE DISTRIBUÉ

Stocker de très grands volumes de données de manière fiable et scalable.

HDFS (Hadoop Distributed File System)

- Stockage distribué sur cluster
- Réplication des blocs
- Tolérance aux pannes
- Adapté aux traitements batch

Amazon S3

- Stockage objet cloud
- Scalabilité quasi infinie
- Haute durabilité
- Utilisé comme data lake moderne

TRAITEMENT DES DONNÉES (BATCH)

Analyser et transformer de grandes quantités de données.

MapReduce

- Modèle de calcul distribué
- Traitement batch
- Robuste mais lent
- Peu flexible

Apache Spark

- Traitement en mémoire
- Très rapide
- APIs haut niveau (SQL, Python)
- Batch, streaming, ML

STREAMING DE DONNÉES

Traiter des données en temps réel.

Apache Kafka

- Plateforme de streaming distribuée
- Publication / souscription Haute
- performance Durable et scalable
-

Spark Streaming / Structured Streaming

- Micro-batching
- Intégré à Spark
- SQL et DataFrames

ORCHESTRATION DES WORKFLOWS

Planifier, automatiser et superviser les pipelines de données.

Apache Airflow

- Orchestration par DAG
- Très utilisé en production
- Python-based

Apache Oozie

- Orchestrateur Hadoop historique
- Moins flexible
- Dépend fortement de l’écosystème Hadoop

Analyse analytique à grande échelle (OLAP).

Apache Hive

- SQL sur HDFS
- Intégré à Hadoop
- Performances limitées

Google BigQuery

- Data warehouse serverless
- Très rapide
- SQL standard
- Facturation à l’usage

ARCHITECTURE HADOOP

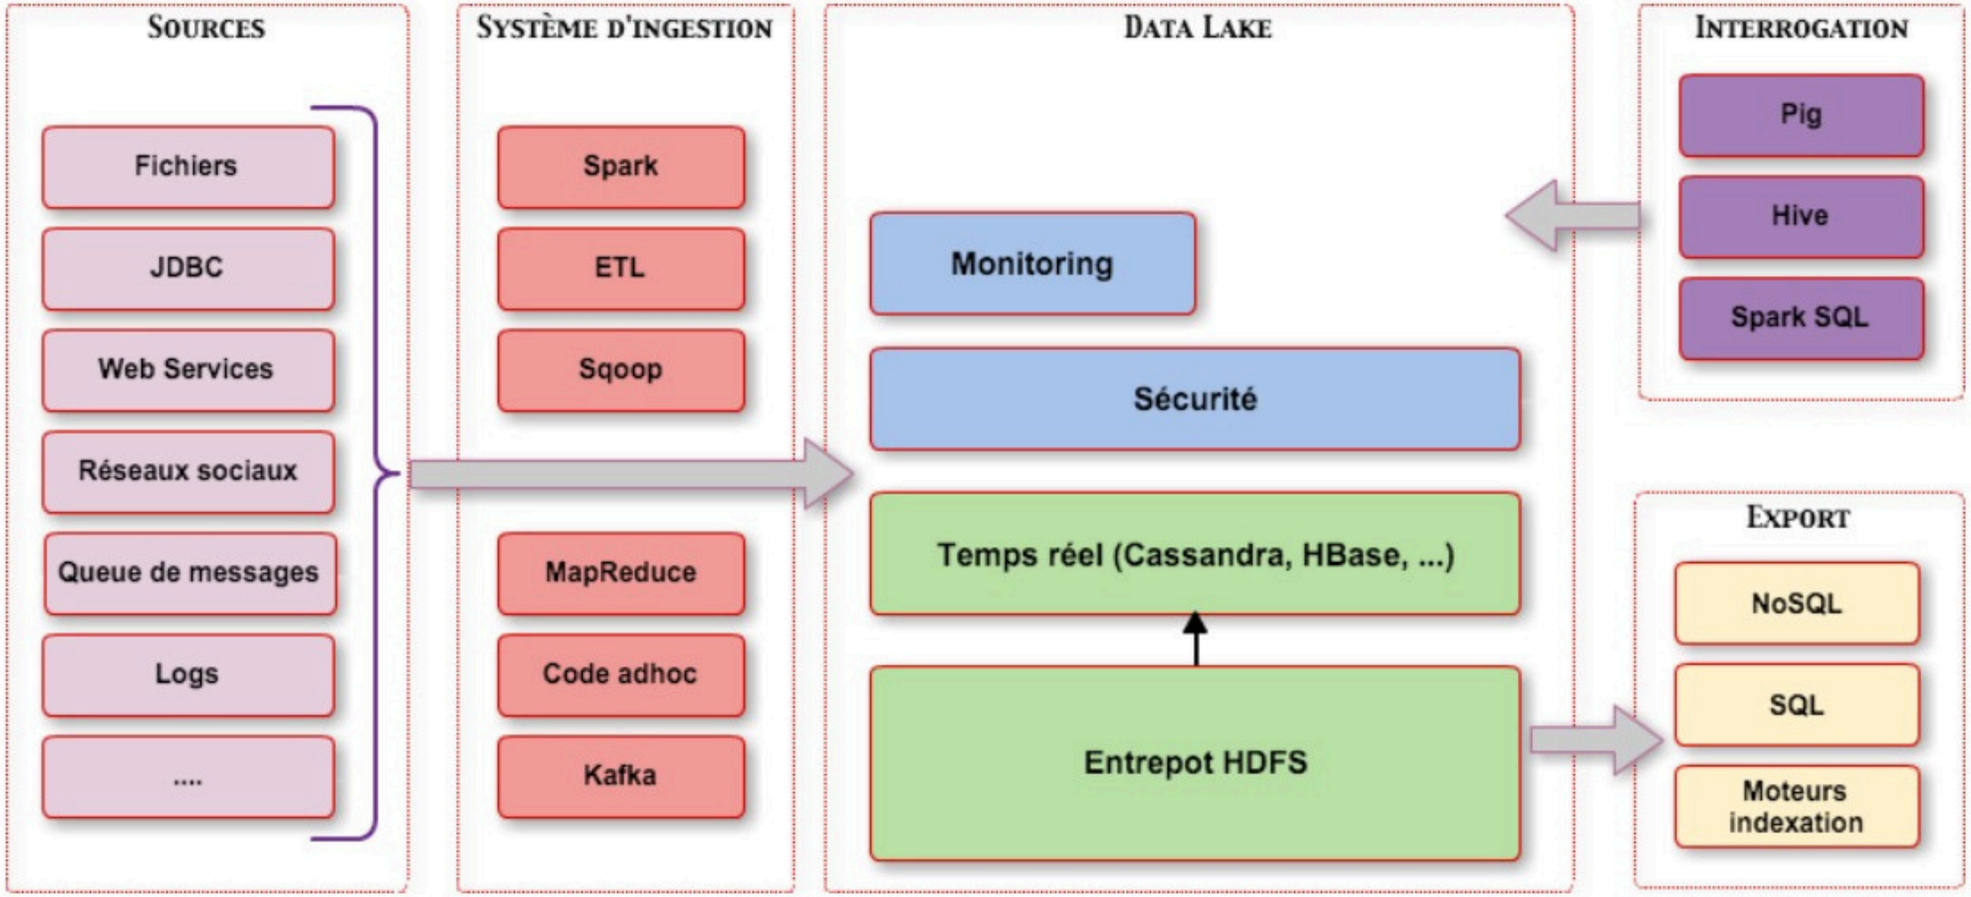

HADOOP : VUE D’ENSEMBLE

Hadoop est un framework qui va permettre le traitement de données massives sur un cluster, allant de une à plusieurs centaines de machines. **Hadoop** est écrit en **Java** et a été créé par **Doug Cutting** et **Michael Cafarella** en 2005 . **Hadoop** va gérer la distribution des données au cœur des machines du **cluster**, leurs éventuelles défaillances, mais aussi l’agrégation du traitement final. L’architecture est de type « **Share nothing** » : aucune donnée n’est traitée par deux **nœuds** différents, même si les données sont réparties sur plusieurs **noeuds** (principe d’un noeud primaire et de noeuds secondaires).

HADOOP : VUE D'ENSEMBLE

Hadoop se compose de trois éléments principaux : **Hadoop HDFS**, **Hadoop MapReduce** et **Hadoop YARN**. Voyons comment ces trois composants s'articulent dans **Hadoop** :

- **Hadoop HDFS** : le système de fichiers distribué Hadoop (HDFS) est l'unité de stockage d'Hadoop.
- **Hadoop MapReduce** : Hadoop MapReduce est l'unité de traitement d'Hadoop. Ce framework logiciel permet d'écrire des applications pour traiter de grandes quantités de données.
- **Hadoop YARN** : Hadoop YARN est un composant de gestion de ressources dans Hadoop. Il traite les données pour effectuer des opérations de traitement par batch, de streaming, interactif et graphique, dont le résultat est stocké dans HDFS.

HDFS : HADOOP DISTRIBUTED FILE SYSTEM

HDFS est un système de fichiers utilisé pour stocker des données structurées ou pas sur un ensemble de serveurs. C’est un système distribué, extensible et portable développé par le créateur d’Hadoop et inspiré du système développé par Google (GoogleFS). Écrit en Java, il a été conçu pour stocker de très gros volumes de données sur un grand nombre de machines équipées de disques durs standard.

Caractéristiques

- Fichiers découpés en blocs (128 MB par défaut)
- Blocs répartis sur plusieurs nœuds
- Accès séquentiel optimisé
- Tolérance aux pannes

ARCHITECTURE HDFS

NameNode (Maître)

- Gère les métadonnées
- Connaît l’emplacement des blocs
- Pas de stockage des données elles-mêmes

DataNodes (Workers)

- Stockent les blocs de données
- Exécutent les lectures/écritures
- Envoient des heartbeats au NameNode

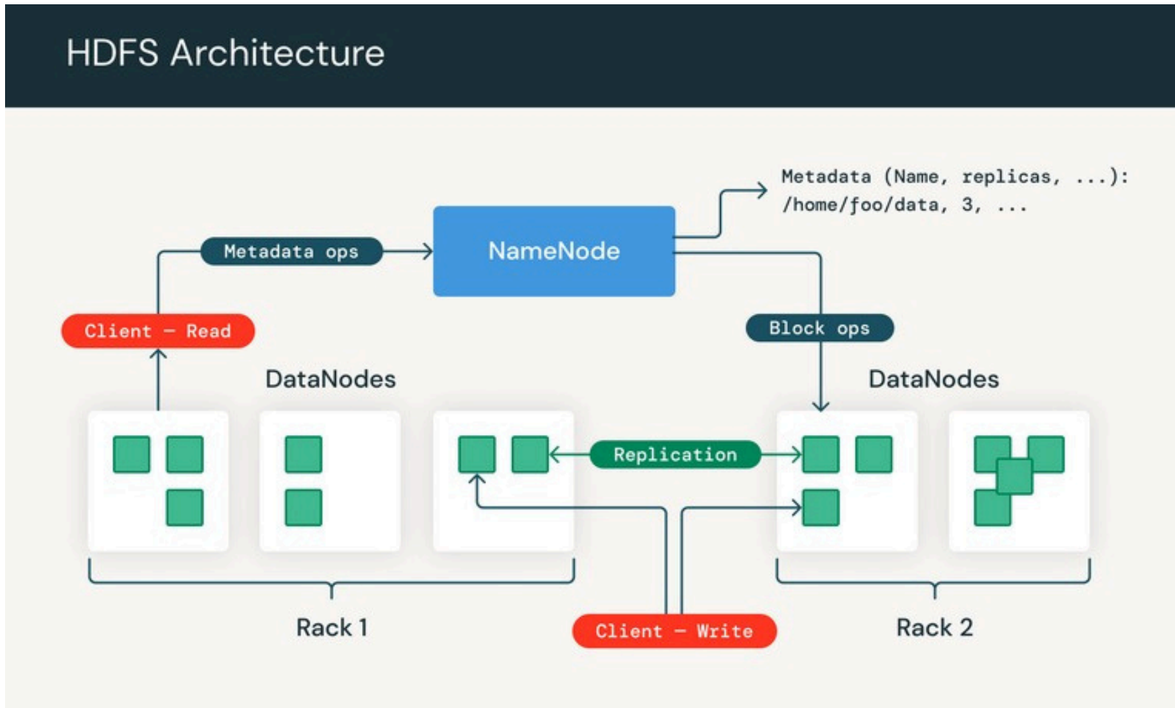

RÉPLICATION & TOLÉRANCE AUX PANNES

Réplication

- Chaque bloc est répliqué (facteur par défaut = 3)
- Répliques sur différents DataNodes

Tolérance aux pannes

- Détection automatique des nœuds défaillants
- Re-réplication des blocs manquants
- Haute disponibilité

Exemple :

Si un **DataNode** tombe → données toujours accessibles

YARN : GESTION DES RESSOURCES

Partager les ressources du cluster entre plusieurs applications.

ResourceManager (Maître)

- Planifie l’exécution des jobs
- Alloue CPU et mémoire

NodeManager (Workers)

- Gère les ressources locales
- Lance les containers
- Rapporte l’état au ResourceManager

Introduction à MapReduce

Principe

Modèle de calcul distribué basé sur :

- Map → transformation des données
- Shuffle → regroupement par clé
- Reduce → agrégation finale

Cas typique

- Comptage
- Agrégations
- Indexation

Hadoop MapReduce

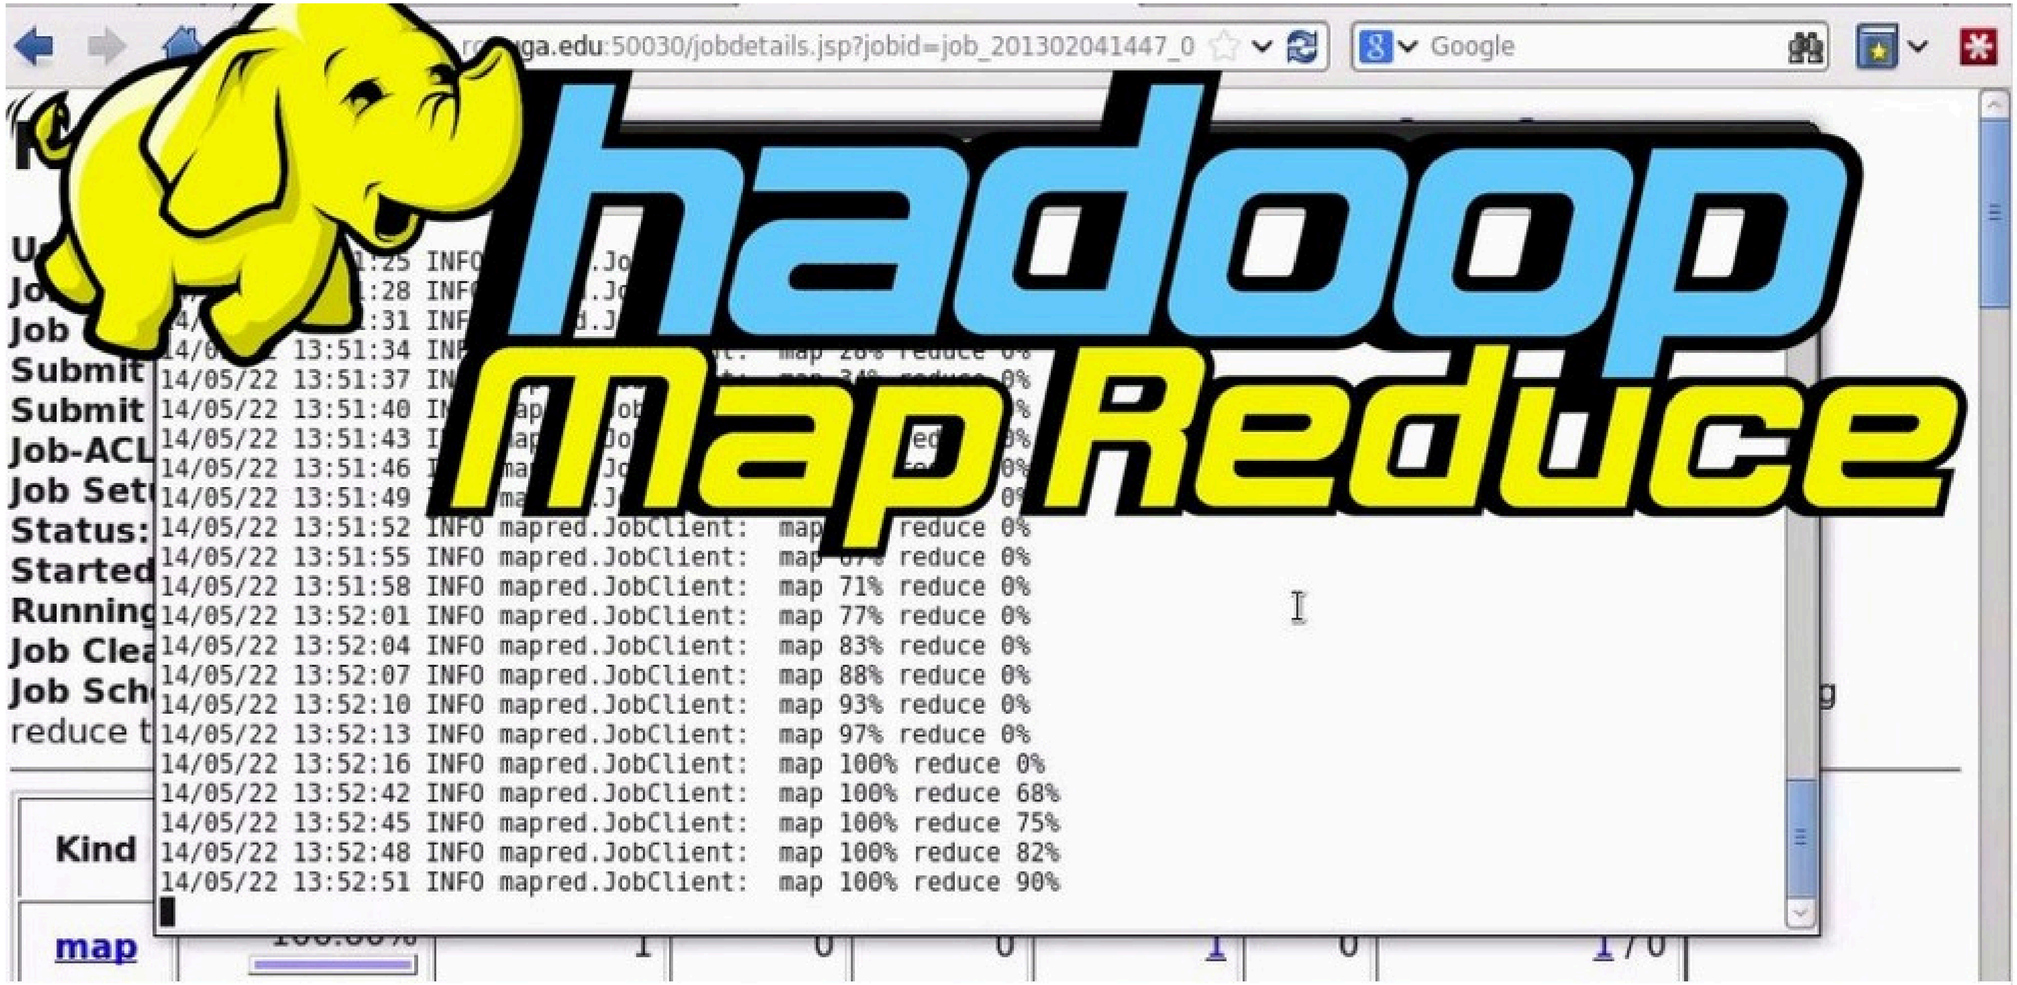

Qu’est-ce que MapReduce ?

MapReduce est un modèle de **programmation** créé par **Google** pour le traitement et la génération de larges ensembles de données sur des clusters d’ordinateurs. Il s’agit d’un composant central du Framework logiciel Apache Hadoop, qui permet le traitement résilient et distribué d’ensembles de données non structurées massifs sur des clusters d’ordinateurs, au sein desquels chaque nœud possède son propre espace de stockage.

Cycle de vie d’un job MapReduce

1. Lecture des données depuis HDFS
2. Phase Map
3. Phase Shuffle & Sort
4. Phase Reduce
5. Écriture des résultats dans HDFS

Le calcul est exécuté au plus près des données.

Cycle de vie d'un job MapReduce

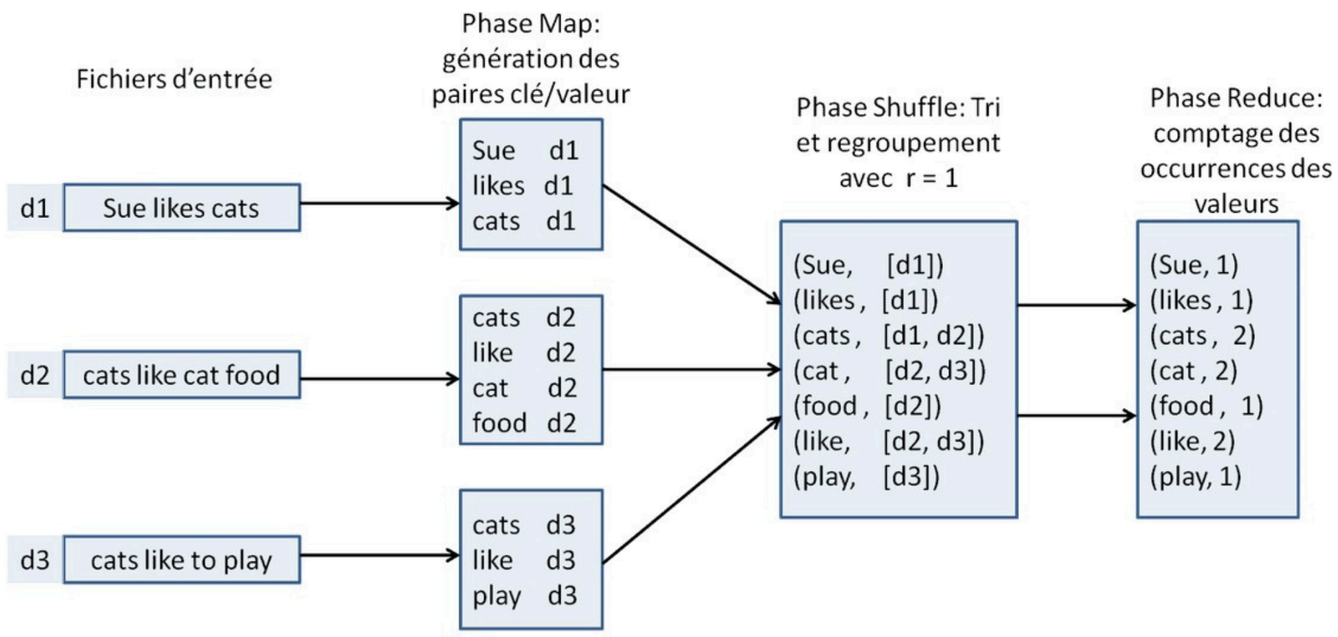

Rôle du Mapper

- Transforme les données d'entrée
- Produit des paires (clé, valeur)

Rôle du Reducer

- Agréger les valeurs associées à une clé

Rôle Shuffle & Sort

- Regrouper les valeurs par clé
- Trier les clés
- Acheminer vers les reducers

Apache Hive

Objectif

Interroger les données HDFS avec du SQL.

Caractéristiques

- Langage HiveQL
- Conversion SQL → MapReduce / Spark
- Adapté à l’analytique batch

Apache HBase

- Base NoSQL orientée colonnes
- Accès temps réel
- Stockée sur HDFS
- Inspirée de Google BigTable

Sqoop & Flume

Sqoop

- Import/export entre Hadoop et bases relationnelles

Flume

- Ingestion de données en streaming
- Logs, événements

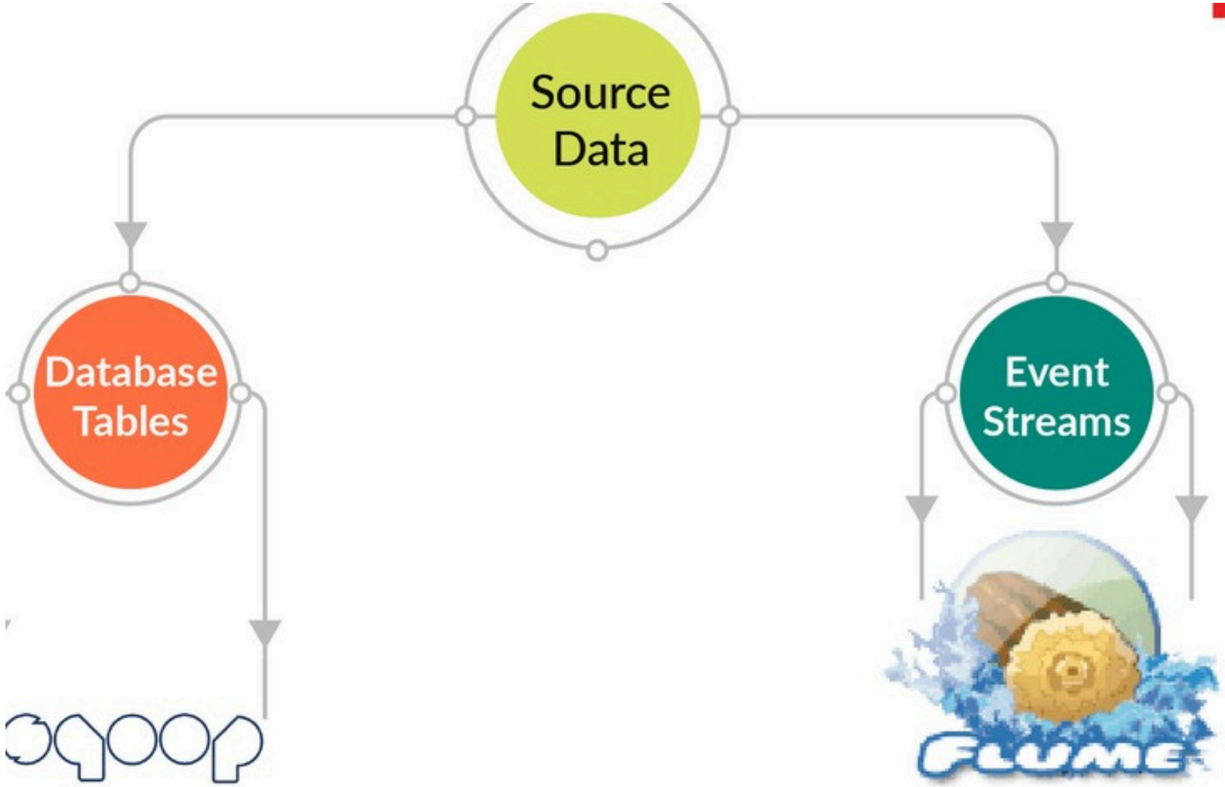

Apache Zookeeper

- Service de coordination distribué
- Gestion de la configuration
- Synchronisation
- Élection de leader
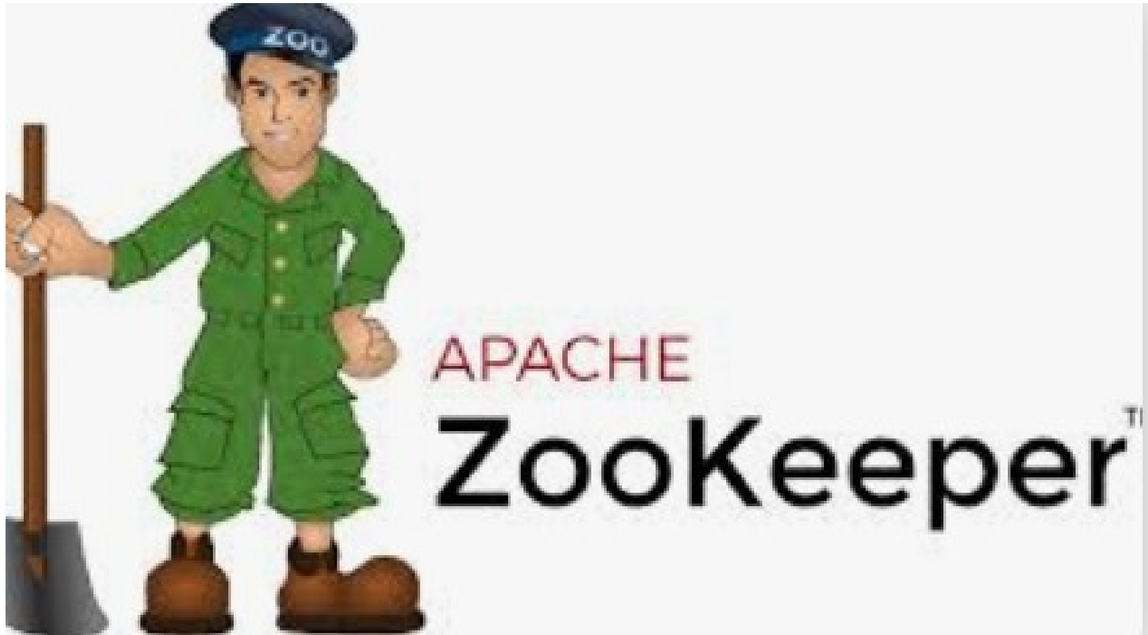
Indispensable pour les clusters distribués.