PROJET BIG DATA · SUP DE VINCI · AVRIL 2026

AutoInsight

La Data au service du marché automobile

Ridwan Abdoulkader Houmed & Henri Turcas

Contexte.

LE DISCOURS OFFICIEL

API - ADEME Car Labelling

Référentiel officiel des performances écologiques et techniques des véhicules neufs.

VS

LA RÉALITÉ DU TERRAIN

Site - AutoScout24

Données réelles du marché de la seconde main collectées par scraping.

« L'impact CO2 influence-t-il réellement le prix de revente ? »

Un pipeline ETL pour confronter théorie et réalité du marché

L'Écosystème Technique.

INGESTION

API & Scraping

- API ADEME
- Scraping AutoScout24
- Données brutes

STOCKAGE

MinIO Data Lake

- Stockage
- Conservation des fichiers bruts
- Versionning des données

TRAITEMENT ET STOCKAGE FINAL

Pandas & PostgreSQL

- Nettoyage
- Entrepôt relationnel

Le Défi de la Véracité.

NETTOYAGE DES DONNÉES

Détection et suppression des valeurs aberrantes.

Exemple de succès :

Dacia à 250 000 € correctement identifiée et exclue du jeu de données.

Les Chiffres qui comptent.

58,1%

Décote moyenne

Perte de valeur entre le prix neuf ADEME et le prix occasion

130

g/km CO2 moyen

Émissions moyennes des véhicules du référentiel ADEME

DÉMONSTRATION

Tableau de bord Streamlit en direct

Bilan

01

Robustesse

Pipeline complet fonctionnelle de l’ingestion à la visualisation.

02

Transparence

Confrontation entre données officielles constructeur et réalité du marché occasion.

03

Maîtrise technique

Docker, scraping, API, PostgreSQL, Streamlit.

Vision .

COURT TERME

Nouvelles sources

Intégration de LeBonCoin et La Centrale pour élargir la couverture marché.

MOYEN TERME

Automatisation

Orchestration avec Apache Airflow pour un pipeline 100% automatisé et planifié.

LONG TERME

Intelligence prédictive

Migration Spark pour le Big Data et modèle ML de prédiction de prix.

Merci.